UNIVERSIDAD COMPLUTENSE DE MADRID

FACULTAD DE CIENCIAS FÍSICAS

DEPARTAMENTO DE FÍSICA DE LA TIERRA Y ASTROFÍSICA



UNIVERSIDAD
COMPLUTENSE
MADRID

Código TFG: [FTA36]

ESTUDIO SOBRE TÉCNICAS DE ASIMILACIÓN DE OBSERVACIONES EN RESULTADOS DE MODELOS METEOROLÓGICOS

STUDY ON TECHNIQUES FOR ASSIMILATION OF OBSERVATIONS INTO METEOROLOGICAL MODEL OUTPUTS

Supervisor: Luis Durán Montejano

Alejandro Avellaneda Calderón

Grado en Física. Doble Grado en Matemáticas–Física

Curso académico 2025/2026

Convocatoria Ordinaria

Resumen

La asimilación de datos constituye una herramienta fundamental en la predicción meteorológica moderna, pues permite combinar de forma coherente observaciones experimentales y modelos numéricos para obtener estimaciones más precisas del estado atmosférico. En este trabajo se presenta una revisión bibliográfica de las principales técnicas de asimilación de datos utilizadas en meteorología, prestando especial atención a los métodos secuenciales y variacionales. En particular, se estudian el filtro de Kalman y las técnicas 3DVAR y 4DVAR, ampliamente empleadas en sistemas actuales de reanálisis atmosférico.

Por otro lado, se implementa numéricamente un esquema 4DVAR sobre el modelo caótico de Lorenz-96 con el objetivo de reconstruir el estado inicial del sistema a partir de observaciones parciales y ruidosas. Los resultados obtenidos muestran la capacidad de esta técnica para reducir significativamente el error en la estimación del estado y ponen de manifiesto la importancia de la asimilación de datos en la modelización de sistemas atmosféricos complejos.

Palabras clave: Asimilación de datos, 4DVAR, filtro de Kalman, Lorenz-96, reanálisis atmosférico.

Abstract

Data assimilation is a fundamental tool in modern weather forecasting, as it enables the coherent combination of observational data and numerical models in order to obtain more accurate estimations of the atmospheric state. This work presents a bibliographic review of the main data assimilation techniques used in meteorology, with special emphasis on sequential and variational methods. In particular, the Kalman filter and the 3DVAR and 4DVAR techniques, widely employed in modern atmospheric reanalysis systems, are studied.

In addition, a 4DVAR scheme is numerically implemented on the chaotic Lorenz-96 model in order to reconstruct the initial state of the system from partial and noisy observations. The obtained results show the ability of this technique to significantly reduce the estimation error and highlight the importance of data assimilation in the modeling of complex atmospheric systems.

Keywords: Data assimilation, 4DVAR, Kalman filter, Lorenz-96, atmospheric reanalysis.

UNIVERSIDAD COMPLUTENSE MADRID

Declaración Responsable sobre Autoría y Uso Ético de Herramientas de Inteligencia Artificial (IA)

Yo, **ALEJANDRO**

AVELLANEDA CALDERÓN

Con DNI: **01673901F**

declaro de manera responsable que el/la presente:

- ☐ **Trabajo de Fin de Grado (TFG)**

Titulado/a

ESTUDIO SOBRE TÉCNICAS DE ASIMILACIÓN DE OBSERVACIONES EN RESULTADOS DE MODELOS METEOROLÓGICOS

es el resultado de mi trabajo intelectual personal y creativo, y ha sido elaborado de acuerdo con los principios éticos y las normas de integridad vigentes en la comunidad académica y, más específicamente, en la Universidad Complutense de Madrid.

Soy, pues, autor del material aquí incluido y, cuando no ha sido así y he tomado el material de otra fuente, lo he citado o bien he declarado su procedencia de forma clara -incluidas, en su caso, herramientas de inteligencia artificial-. Las ideas y aportaciones principales incluidas en este trabajo, y que acreditan la adquisición de competencias, son mías y no proceden de otras fuentes o han sido reescritas usando material de otras fuentes.

Asimismo, aseguro que los datos y recursos utilizados son legítimos, verificables y han sido obtenidos de fuentes confiables y autorizadas. Además, he tomado medidas para garantizar la confidencialidad y privacidad de los datos utilizados, evitando cualquier tipo de sesgo o discriminación injusta en el tratamiento de la información.

En Madrid a **29 DE MAYO DE 2026**

FIRMA



Índice de contenidos

1 Introducción. Motivación histórica y objetivos **2**

2 Fundamentos teóricos de la asimilación de datos **3**

2.1 Formulación general del problema 3

2.2 Enfoque probabilístico y variacional del problema de asimilación 4

2.3 Clasificación de las técnicas de asimilación 5

3 Técnicas de asimilación: secuenciales y variacionales **6**

3.1 Métodos secuenciales. Filtro de Kalman y posibles extensiones 6

3.2 Métodos variacionales. Técnicas 3DVAR y 4DVAR 8

3.3 Filtros de Kalman vs Técnicas Variacionales: Discusión Comparativa 11

4 Implementación numérica de un sistema de DA. Metodología **12**

4.1 El modelo Lorenz-96 12

4.2 Configuración y diseño del experimento 13

5 Resultados experimentales **16**

5.1 Validación del gradiente 16

5.2 Resultados del experimento base 16

5.3 Análisis de sensibilidad 17

6 Conclusiones y perspectivas futuras **19**

Capítulo 1

Introducción. Motivación histórica y objetivos

La predicción meteorológica ha intrigado y fascinado a la humanidad durante miles de años. Sin embargo, la falta de un formalismo científico sólido, así como de herramientas matemáticas capaces de modelizar con éxito el comportamiento atmosférico, relegó la predicción meteorológica a áreas pseudocientíficas y religiosas durante la Edad Antigua y buena parte de la Edad Media. No obstante, con la invención del cálculo diferencial e integral en el siglo XVII y el posterior desarrollo del Análisis Matemático durante los siglos XVIII y XIX quedó patente que, a priori, la naturaleza podría describirse mediante leyes matemáticas precisas. En consecuencia, la atmósfera parecía no ser una excepción. La formalización matemática del comportamiento atmosférico y climático abrió la puerta a la modelización numérica del tiempo en el siglo XX, con modelos tan famosos como el de convección atmosférica de Lorenz [15]. Sin embargo, estos modelos constituían sistemas altamente no lineales y extremadamente sensibles a las condiciones iniciales. Así, pequeñas incertidumbres en la estimación inicial del estado atmosférico se trasmitían en grandes fluctuaciones a largo plazo, lo que comprometía su carácter determinista. En otras palabras, la atmósfera constituía lo que hoy en la literatura matemática se denomina *sistema caótico* gracias a autores como Devaney [6].

En este contexto, la cuestión fundamental dejó de ser únicamente el estudio del comportamiento de las soluciones a las ecuaciones que rigen el sistema, y se añadió el problema de determinar, con la mayor precisión posible, su estado inicial. No obstante, dado que las observaciones disponibles son siempre parciales y sujetas a incertidumbres intrínsecas del proceso de medida, la reconstrucción del estado inicial atmosférico exigía desarrollar herramientas que combinasen de forma coherente la información empírica con la obtenida vía el modelo matemático. Es precisamente bajo este prisma donde surgen las técnicas de asimilación de datos (*DA*, por sus siglas en inglés), que constituyen el núcleo de los sistemas modernos de reanálisis, gracias a los cuales podemos reconstruir el estado pasado de la atmosféra y comprender mejor su evolución. En consecuencia, la modelización meteorológica contemporánea descansa, en última instancia, sobre la calidad de los reanálisis y técnicas de asimilación de observaciones.

El presente trabajo constituye una revisión bibliográfica de las principales técnicas de asimilación de datos en resultados de modelos meteorológicos e implementa numéricamente una de estas técnicas, evaluando su robustez y eficiencia.

El Capítulo 2 presenta el marco teórico de la asimilación de datos, que establece la base matemática del problema, mientras que el Capítulo 3 aborda en detalle estas técnicas, siguiendo la clasificación clásica de las mismas según autores expertos en el campo. Por otro lado, en el Capítulo 4 se implementa numéricamente un esquema de asimilación sobre un modelo puramente académico, y se analiza su robustez y respuesta a diferentes tests de sensibilidad; los resultados de esta implementación numérica se muestran en el Capítulo 5. Además, se comparan los resultados obtenidos con productos de reanálisis reales llevados a cabo en los grandes centros meteorológicos actuales, con el objetivo de contextualizar la metodología desarrollada dentro de los sistemas reales de predicción y modelización. Finalmente, el Capítulo 6 resume los principales resultados y conceptos desarrollados, y expone las posibles líneas futuras de investigación.

Capítulo 2

Fundamentos teóricos de la asimilación de datos

En este primer capítulo se pretende proporcionar una base matemática y conceptual sólida sobre la que desarrollar las técnicas de asimilación de datos y de reanálisis. En particular, se exponen los diferentes marcos dentro de los cuales se puede entender la asimilación de datos, y se introducen las dos grandes familias de técnicas en las que profundizaremos en el siguiente capítulo.

2.1. Formulación general del problema

La asimilación de datos surge al intentar estimar el estado inicial de un sistema físico, en este caso la atmósfera, cuando se dispone de un modelo matemático que describe su evolución y de una serie de observaciones. No obstante, las observaciones de las que se disponen habitualmente son parciales o ruidosas, y tanto éstas como el propio modelo contienen errores que no deben ser despreciados. La necesidad de integrar de forma coherente todas estas fuentes de información da lugar al problema del reanálisis, entendido, según autores como Navon [17], como la reconstrucción retrospectiva del estado atmosférico más consistente con el modelo físico y con el conjunto global de observaciones disponibles.

Así, matemáticamente un estado atmosférico puede representarse como un vector $x_k \in \mathbb{R}^n$, con n muy alto en modelos operativos (actualmente, los modelos matemáticos admiten vectores del orden de $10^8 - 10^9$ grados de libertad), y un modelo matemático como una expresión discreta, al provenir ésta de la necesaria discretización de las ecuaciones para su posterior tratamiento numérico, de la forma

$$x_{k+1} = \mathcal{M}_{k,k+1}(x_k) + \eta_k \tag{2.1}$$

donde η_k indica el error de modelado, entendido como la diferencia entre la evolución real del sistema físico y la predicha por el operador $\mathcal{M}$; esta notación es estándar en la literatura científica, como muestran artículos como [2]. Por otro lado, una observación puede describirse como un vector $y_k \in \mathbb{R}^p, p \ll n$, vía un operador $\mathcal{H}$, que proyecta del espacio del modelo al espacio observable, de forma que

$$y_k = \mathcal{H}(x_k) + \varepsilon \tag{2.2}$$

donde ε denota el error o incertidumbre observacional, implícito en el proceso de medida [2]. Denotaremos por x_k^{true} el estado verdadero del sistema físico en el instante t_k, desconocido en la práctica. Por otro lado, para cada k el estado previo o *de fondo* x_b es una estimación del estado obtenida sin incorporar las observaciones disponibles en t_k, frecuentemente de reanálisis anteriores. Definiremos el *error de fondo* $e_k^b \coloneqq x_k^{true} - x_b$ como la diferencia entre estos dos valores. Además, con el objetivo de abordar el problema problema de forma eficiente, establecemos algunas hipótesis previas, muy habituales en la literatura, como son [13]:

1. El error de fondo es una variable aleatoria gaussiana $\implies \forall k, \quad e_k^b \sim \mathcal{N}(0, B)$, donde $B \in \mathbb{R}^{n \times n}$, o matriz de covarianza, es simétrica y definida positiva.
2. Los errores siguen una distribución de tipo gaussiana $\implies \eta_k \sim \mathcal{N}(0, P), \quad \varepsilon \sim \mathcal{N}(0, R)$

3. Los errores de modelado y observacionales son independientes $\implies Cov(\eta_k, \varepsilon) = 0 \quad \forall k \in [0, N]$, siendo $N+1$ el número de nodos del mallado temporal $\{t_0, ...t_N\}$.

Bajo estas hipótesis, la reconstrucción del estado atmosférico pasado a partir de observaciones parciales constituye un problema inverso dinámico, cuya solución requiere cohesionar, de manera óptima y equilibrada, la información proveniente del modelo y de estas observaciones. Así, la asimilación de datos puede entenderse como la reconstrucción óptima de un estado dinámico en alta dimensión, formulada como un problema inverso en el que se busca compatibilizar coherencia física y ajuste observacional.

2.2. Enfoque probabilístico y variacional del problema de asimilación

Muchos de los esquemas actuales de asimilación de datos están basados en lo que se conoce como *inferencia bayesiana*, como puede verse en artículos como el de Alonso González et al. [2]. En esta formulación, el objetivo es determinar la distribución $p(x|y)$, o probabilidad de que dada una observación $y \in \mathbb{R}^p$ el estado real sea $x \in \mathbb{R}^n$. Esta distribución, llamada distribución *a posteriori*, puede ser inferida gracias al teorema de Bayes,

$$p(x|y) = \frac{p(y|x)p(x)}{p(y)} \tag{2.3}$$

donde $p(y|x)$ es la probabilidad de observar y dado un estado x y $p(x)$ la probabilidad del estado x antes de considerar las observaciones. En la interpretación bayesiana del problema se entiende el vector x de estado como uno formado por variables aleatorias, y el vector y como uno determinista una vez fijado x. Así, bajo esta perspectiva el denominador $p(y)$ funciona simplemente como una normalización de la distribución a posteriori, y se tiene que

$$p(x \mid y) \propto p(y \mid x)\, p(x),$$
$$\arg\max_x p(x \mid y) = \arg\max_x p(y \mid x)\, p(x).$$

En consecuencia, el estado estimado corresponde a lo que en estadística se denomina estimador MAP (Maximum A Posteriori) [13]. Así, bajo la hipótesis anterior sobre el error de fondo establecemos un *prior* gaussiano de x, es decir, para cada t_k suponemos inicialmente $x \coloneqq x_k^{true} \sim \mathcal{N}(x_b, B), B > 0$, y que $y = \mathcal{H}(x) + \varepsilon, \varepsilon \sim \mathcal{N}(0, R)$. Como x es una variable aleatoria de tipo gaussiana, puede verse, siguiendo el razonamiento matemático propuesto por Law et al. [13], que

$$p(x) \propto \exp\left(-\frac{1}{2}(x - x_b)^T B^{-1}(x - x_b)\right),$$

$$p(y \mid x) = p(\varepsilon) \propto \exp\left(-\frac{1}{2}(y - H(x))^T R^{-1}(y - H(x))\right),$$

$$p(y \mid x)\, p(x) \propto \exp\left(-\frac{1}{2}(x - x_b)^T B^{-1}(x - x_b) - \frac{1}{2}(y - H(x))^T R^{-1}(y - H(x))\right)$$

Así, definiendo la función

$$\mathcal{J}(x) = \frac{1}{2}(x - x_b)^T B^{-1}(x - x_b) + \frac{1}{2}(y - H(x))^T R^{-1}(y - H(x)) \tag{2.4}$$

se tiene que $p(x|y) \propto exp(-\mathcal{J}(x))$, y que, por tanto,

$$\arg\max_x p(x \mid y) = \arg\min_x \mathcal{J}(x)$$

con lo que el problema de maximizar una probabilidad bayesiana puede abordarse como uno de optimización. Finalmente, si el estado evoluciona dinámicamente en una ventana temporal $[t_0, t_N]$, en la que se tienen observaciones $y_0, .., y_N$, la distribución a posteriori conjunta puede escribirse como un producto de distribuciones independientes, por lo que

$$p(x_0 \mid y_{0:N}) \propto \exp\big(-\mathcal{J}(x_0)\big),$$

con

$$\mathcal{J}(x_0) = \frac{1}{2}(x_0 - x_b)^T B^{-1}(x_0 - x_b) + \frac{1}{2}\sum_{k=0}^{N}\left(y_k - H_k(x_k)\right)^T R_k^{-1}\left(y_k - H_k(x_k)\right) \tag{2.5}$$

Esta expresión es igual a la obtenida por Ionel M. Navon en [17], y constituye, como veremos en capítulos posteriores, el punto de partida de las técnicas de asimilación variacionales, en particular de la técnica 4DVAR y sus derivadas.

2.3. Clasificación de las técnicas de asimilación

Hoy en día, la clasificación más aceptada de las técnicas de asimilación de datos, presente en la literatura científica en trabajos como los de Kalnay [11] o Talagrand [19], y en la que profundizaremos en el siguiente capítulo, agrupa las técnicas de asimilación de datos en dos grandes familias, dependiendo de cómo integran la información observacional con la obtenida vía modelo matemático.

Por un lado, las técnicas *secuenciales*, más pensadas para predicción meteorológica, actualizan la información "paso a paso", es decir, actualizan el estado del sistema cada vez que llega una nueva observación, propagando de esta forma en el tiempo tanto la estimación como su incertidumbre. Aquí, conceptos como el de ganancia y técnicas como la del filtro de Kalman y sus derivadas serán especialmente relevantes.

Por otro lado, las técnicas *variacionales* persiguen obtener un estado inicial que minimice la función $\mathcal{J}$ de la sección anterior, y plantean el problema como uno global dentro de la ventana temporal de asimilación. Bajo este enfoque, técnicas como el 3DVAR o el más reciente 4DVAR cobran especial importancia.

Finalmente, es necesario exponer que estas dos visiones, aunque conceptualmente distintas, no son excluyentes, y de hecho veremos que coexisten en la mayoría de modelos de reanálisis actuales, dando lugar a métodos híbridos que combinan las ventajas de ambos enfoques.

Capítulo 3

Técnicas de asimilación: secuenciales y variacionales

En este capítulo profundizamos en las diferentes familias de técnicas de asimilación siguiendo la clasificación presentada en el capítulo anterior según si actualizan la información paso a paso o minimizan un funcional en un intervalo temporal completo. En particular, por su importancia para los reanálisis meteorológicos se hace especial hincapié en las técnicas variacionales, donde se desarrollan en profundidad las técnicas 3DVar y 4DVar como ejemplos paradigmáticos de esta familia.

3.1. Métodos secuenciales. Filtro de Kalman y posibles extensiones

Las técnicas secuenciales, llamadas por autores como Law et al. como técnicas *filtering* o de filtrado en inglés [13], actualizan paso a paso la información relativa al estado x en un tiempo t_k usando únicamente datos acumulados desde t_0 a t_k. El nombre de filtrado no es al azar, puesto que en esencia, estas técnicas actúan como un filtro que limpia el ruido (error) observacional y produce una estimación óptima del estado. Así, sea $Y_j = \{y_l\}_{l=0}^{j}$ la información observacional acumulada desde el origen hasta un tiempo t_j. El problema de *filtering* está relacionado con determinar el posteriori $p(x_j|Yj)$, y su actualización secuencial a medida que j va creciendo. Esta actualización, que permite determinar $p(x_{j+1}|Y_{j+1})$ a partir de $p(x_j|Yj)$, se lleva a cabo, según los autores previamente mencionados, en dos pasos, correspondientes, en el contexto meteorológico, a la propagación del estado mediante el modelo numérico de predicción y a su corrección cuando se incorporan nuevas observaciones:

1. **Predicción**: permite determinar $p(x_{j+1}|Y_j)$ a partir de $p(x_j|Y_j)$. Para ello, nótese que $p(x_{j+1}|Y_j, x_j) = p(x_{j+1}|x_j)$, puesto que de la expresión 2.1 se extrae que el proceso es de tipo Markoviano, en el que el estado en tiempo k depende únicamente del estado en tiempo $k-1$. En consecuencia, aplicando el teorema de Bayes 2.2, se tiene que

$$\begin{aligned} p(x_{j+1} \mid Y_j) &= \int_{\mathbb{R}^n} p(x_{j+1} \mid Y_j, x_j)\, p(x_j \mid Y_j)\, dx_j \\ &= \int_{\mathbb{R}^n} p(x_{j+1} \mid x_j)\, p(x_j \mid Y_j)\, dx_j. \end{aligned} \tag{3.1}$$

   A la ecuación 3.1 se la conoce como *ecuación de Chapman-Kolmogorov*, y es de vital importancia en procesos estocásticos de tipo markoviano como el que tenemos.

2. **Análisis**: calcula $p(x_{j+1}|Y_{j+1})$ a partir de $p(x_{j+1}|Y_j)$. Para ello, nótese ahora, por un razonamiento análogo al del paso predictivo, que $p(y_{j+1}|x_{j+1}, Y_j) = p(y_{j+1}, x_{j+1})$. Así, usando nuevamente la fórmula de Bayes, se tiene que

$$\begin{aligned} p(x_{j+1} \mid Y_{j+1}) &= p(x_{j+1} \mid Y_j, y_{j+1}) \\ &= \frac{p(y_{j+1} \mid x_{j+1})\, p(x_{j+1} \mid Y_j)}{p(y_{j+1} \mid Y_j)}. \end{aligned} \tag{3.2}$$

Las ecuaciones 3.1 y 3.2 definen el esquema general de los métodos de *filtering*, basados en la teoría bayesiana sobre operadores discretos. Sin embargo, en general las integrales involucradas no

admiten expresiones analíticas o cerradas, por lo que se requieren aproximaciones para abordar el problema. La naturaleza de estas aproximaciones radicará, siempre según [13], en la estructura del operador dinámico $\mathcal{M}$, del operador de observación $\mathcal{H}$ y de la naturaleza de los errores, que generalmente asumiremos gaussiana como ya se indicó en el capítulo 2.

De las técnicas secuenciales, el ejemplo paradigmático es el **filtro de Kalman** [4] [13], pues permite resolver el problema general cuando $\mathcal{M}$ y $\mathcal{H}$ son lineales, es decir, cuando

$$\mathcal{M}(x) = Mx, \quad \mathcal{H}(y) = Hy$$

con $M \in \mathbb{R}^{n\times n}, H \in \mathbb{R}^{p\times n}$. Asumiremos $p \leq n$ y $rg(H) = p$. En este caso, la distribución $p(x_j|Y_j)$ a actualizar es de tipo gaussiana, puesto que gracias al trabajo de Law et al. se sabe que 3.1 y 3.2 preservan gaussianidad, y por tanto puede ser caracterizada por su media y matriz de covarianzas. Así, sea (m_j, C_j) la media y covarianza de $x_j|Y_j$, y sea $(\hat{m}_{j+1}, \hat{C}_{j+1})$ la media y covarianza de $x_{j+1}|Y_j$; como ambas distribuciones son gaussianas, estas duplas caracterizan por completo a las variables aleatorias involucradas. Bajo estas condiciones, las ecuaciones que definen el filtro de Kalman, y que permiten obtener (m_{j+1}, C_{j+1}) a partir de (m_j, C_j), son

$$\boxed{\begin{aligned}
\hat{m}_{j+1} &= Mm_j, \\
\hat{C}_{j+1} &= MC_jM^T + P, \\
d_{j+1} &= y_{j+1} - H\hat{m}_{j+1}, \\
S_{j+1} &= H\hat{C}_{j+1}H^T + R, \\
K_{j+1} &= \hat{C}_{j+1}H^T S_{j+1}^{-1}, \\
m_{j+1} &= \hat{m}_{j+1} + K_{j+1}d_{j+1}, \\
C_{j+1} &= (I - K_{j+1}H)\hat{C}_{j+1}
\end{aligned}} \tag{3.3}$$

donde P indica la matriz de covarianzas del error de modelado, R la matriz de covarianzas del error observacional, y K_{j+1}, llamada *ganancia de Kalman*, indica cuánto peso se le da a la observación frente al modelo en la actualización de estado, y se obtiene minimizando $\mathbb{E}\,\|x_{j+1} - m_{j+1}\|^2$. La deducción de estas ecuaciones a partir de las hipótesis de gaussianidad y linealidad de los operadores combina álgebra lineal con teoría de la probabilidad, y puede consultarse en [13].

El filtro de Kalman es la solución explícita del problema MAP del capítulo anterior bajo las hipotésis de linearidad de los operadores y gaussianidad en el ruido. La importancia del filtro de Kalman reside en que bajo unas condiciones adecuadas resuelve de manera exacta las integrales planteadas en las ecuaciones 3.1,3.2, proporcionando una solución exacta a un problema estructural en la asimilación de datos. Además, simplifica el problema enormemente al reducir la propagación de distribuciones de probabilidad a un problema de propagación de matrices, al quedar las distribuciones completamente determinadas por su media y covarianzas. Finalmente, el filtro de Kalman introduce el concepto de *ganancia óptima* en forma de matriz K_j, como equilibrio ponderado entre información proveniente del modelo e información observacional. Esta idea de optimalidad en el balance es la base de toda técnica asimilación de datos actual, y toda la teoría posterior está fundamentada en este concepto.

Sin embargo, en modelos operativos actuales, donde los estados tienen el orden de $n \sim 10^8 - 10^9$ variables, la aplicación directa del filtro de Kalman es computacionalmente inviable al requerir la reiterada construcción de matrices de tamaño $n \times n$. Además, el modelo lineal supone una primera aproximación, que en muchas ocasiones resulta insuficiente. Para salvar estos obstáculos, se han hecho ampliaciones del filtro de Kalman, como son el filtro de Kalman *extendido* (EKF, por sus siglas en inglés), que linealiza localmente $\mathcal{M}$ reemplazando el modelo por su Jacobiano,

permitiendo tratar con sistemas no lineales, o el filtro de Kalman *por conjuntos* (en inglés, "ensembles"), EnKF, que en lugar de considerar la matriz $\hat{C_{j+1}}$, considera

$$\hat{m}_{j+1} = \frac{1}{N}\sum_{n=1}^{N} x_{j+1}^{(n)}, \qquad \hat{C}_{j+1} = \frac{1}{N-1}\sum_{n=1}^{N}\left(x_{j+1}^{(n)} - \hat{m}_{j+1}\right)\left(x_{j+1}^{(n)} - \hat{m}_{j+1}\right)^T.$$

reduciendo el problema computacional a uno $O(nN)$ en lugar de uno $O(n^2)$. Hoy, modelos como los de ECMWF ([4]) o NOAA ([1]) emplean las técnicas secuenciales derivadas del filtro de Kalman para actualizar el estado atmosférico cuando llegan datos, sin necesidad de recalcular todo desde cero, o para generar predicciones por conjuntos, donde usando el EnKF generan conjuntos de predicción con los que estiman la incertidumbre y evalúan la dispersión del modelo.

3.2. Métodos variacionales. Técnicas 3DVAR y 4DVAR

Los métodos variacionales responden a la necesidad de buscar algoritmos basados en el principio de minimización que subyace a los filtros de Kalman presentados en la sección anterior, extensibles de manera natural a problemas de naturaleza no gaussiana. Según Law et al. ([13]), una de las principales referencias en el estudio teórico de estas familias, en estas técnicas el objetivo ya no es actualizar paso a paso la información, como sucedía en los métodos secuenciales, sino en combinar las observaciones disponibles con la información dada por el modelo para proporcionar una descripción más precisa del estado atmosférico pasado. Además, en los métodos variacionales ya no se trabaja sobre tiempos discretos, sino que se opera de una forma continua, sobre ventanas temporales, usando de manera simultánea todas las observaciones disponibles en esa ventana. En consecuencia, en la resolución de este problema, llamado *smoothing problem* o de suavizado al buscar también una coherencia con observaciones posteriores, los métodos variacionales resultan idóneos. Además, estos métodos son de gran importancia en los *reanálisis*, donde se busca reconstruir el estado de la atmósfera en un tiempo t usando observaciones antes y después de t. En general, en la mayoría de los modelos operativos actuales, la ventana temporal de asimilación cubre típicamente intervalos de 3 a 12h, siendo la de 6h la más usada [18].

Por otro lado, otro aspecto que caracteriza a las técnicas variacionales es que reconstruyen el estado atmosférico vía optimización (minimización) de una función, llamada *función de coste*, cuya expresión es

$$\mathcal{J}(x) = \frac{1}{2}(x - x_b)^T B^{-1}(x - x_b) + \frac{1}{2}(y - H(x))^T R^{-1}(y - H(x)). \tag{3.4}$$

Nótese que esta expresión, presente en textos como [18], es precisamente la función 2.2 que dedujimos en el capítulo 2 partiendo de las hipótesis de gaussianidad y haciendo uso de las técnicas de inferencia bayesiana. Así, la minimización de esta función de coste permite resolver el problema global de una sola vez, en lugar de ir actualizando "por pasos" o de manera secuencial. Es precisamente por esta razón por la que la mayoría de organizaciones meteorológicas hace uso de las técnicas variacionales, estando su uso por tanto ampliamente extendido en la comunidad científica (véase [10]).

Por la extensión de su uso en los modelos operativos actuales y en las organizaciones de más prestigio, las técnicas variacionales más emblemáticas son las técnicas 3DVAR y 4DVAR. La técnica 3DVAR minimiza directamente la función 3.2 para obtener el estado atmosférico x_b. Si el operador H es lineal, ie $H(x) = Hx$, la solución puede obtenerse de manera explícita. No obstante, en la mayoría de modelos actuales el operador de observación H no es lineal, en cuyo caso la solución se obtiene mediante un algoritmo iterativo de minimización [18], que requiere el

cálculo del gradiente de la función de coste con respecto a x en cada paso. Además, el algoritmo 3DVAR no incluye las observaciones dentro de la ventana temporal de asimilación, al trabajar sobre un tiempo t_j fijo. Así, se desarrolla la técnica 4DVAR, en la que a diferencia de la 3DVAR el operador H incluye los modelos dinámicos para evolucionar temporalmente el estado atmosférico. Considerada como una extensión de la 3DVAR, la técnica 4DVAR permite integrar las observaciones distribuidas en la ventana temporal de asimilación en la búsqueda del estado óptimo que reconstruya el pasado atmosférico [18].

Así, en la formulación 4DVAR se integran todas las observaciones realizadas en la ventana temporal de asimilación, y la expresión a minimizar 3.2 queda reescrita, por tanto, como [13], [18]

$$\mathcal{J}(x_0) = \frac{1}{2}(x_0 - x_b)^T B^{-1}(x_0 - x_b) + \frac{1}{2}\sum_{k=0}^{N}\left(y_k - H_k(x_k)\right)^T R^{-1}\left(y_k - H_k(x_k)\right). \tag{3.5}$$

Por otro lado, en el enfoque variacional se asumen modelos perfectos, y por tanto se tiene que la expresión 2.1 queda reescrita como

$$x_{k+1} = \mathcal{M}_{k,k+1}(x_k) \implies x_{k+1} = \mathcal{M}_{k,0}(x_0), \quad \mathcal{M}_{k,0} = \mathcal{M}_{k,k-1} \circ \mathcal{M}_{k-1,k-2} \circ \cdots \circ \mathcal{M}_{1,0} \tag{3.6}$$

Así, podemos sustituir esta cadena en 3.2, y como minimizar implica calcular el gradiente e igualarlo a 0, tenemos que

$$\nabla_{x_0}\mathcal{J}(x_0) = B^{-1}(x_0 - x_b) + \sum_{k=0}^{N} M_{k,0}^{\mathrm{T}} H_k^{\mathrm{T}} R^{-1}\big(\mathcal{H}_k(x_k) - y_k\big) = 0. \tag{3.7}$$

donde H^T es el traspuesto conjugado del operador lineal tangente de H (es decir, el traspuesto de su linealización), y $M_{k,0}^{\mathrm{T}} \coloneqq M_{1,0}^{\mathrm{T}} \cdot \ldots \cdot M_{k,k-1}^{\mathrm{T}}$, llamado típicamente el **modelo adjunto lineal** (ADM, por sus siglas en inglés), representa la traspuesta del jacobiano del modelo dinámico, ie $M_{k,0} = D\mathcal{M}_{k,0}(x_0)$.

En [18] se propone un esquema 4DVAR en el que se minimice 3.2 usando el método del descenso de gradiente. Este algoritmo queda como:

1. Inicialización: $x^0(t_0) = x_b$.
2. Para cada $i = 1, 2, \ldots$:

   2.1 Calcular y guardar la trayectoria de primera aproximación (*first guess*) y la diferencia con la observación $H_k(x_k) - y_k$, integrando el modelo no lineal

   $$x^i(t_k) = \mathcal{M}(t_k, t_0)\big(x^i(t_0)\big).$$

   2.2 Partiendo de la variable adjunta $\delta' x^i(t_N) = 0$, se integra el modelo adjunto hacia atrás en el tiempo, desde t_N hasta t_0. Si durante la integración se encuentran observaciones, el término de forzamiento observacional

   $$\mathcal{H}_k^{\mathrm{T}}\big(H_k(x_k) - y_k\big)$$

   se añade al valor actual de $\delta' x^i(t_k)$. El valor final $\delta' x^i(t_0)$, junto con el término

   $$B^{-1}\big(x^i(t_0) - x_b\big),$$

proporciona el gradiente

$$\nabla \mathcal{J}^i = \delta' x^i(t_0) + B^{-1}\big(x^i(t_0) - x_b\big).$$

En este paso también se calcula el valor de la función de coste $\mathcal{J}(x^i(t_0))$.

2.3 Encontrar el paso óptimo $\rho^i > 0$. Para un modelo lineal, ρ^i puede calcularse explícitamente a partir de la Hessiana de la función de coste. En el caso no lineal, ρ^i debe estimarse numéricamente, generalmente mediante un procedimiento de *line search*.

2.4 Actualizar la aproximación:

$$x^{i+1}(t_0) = x^i(t_0) - \rho^i \nabla \mathcal{J}^i.$$

2.5 Comprobar el criterio de convergencia elegido. Generalmente, este criterio de convergencia es que la norma del gradiente, ie $\|\nabla \mathcal{J}(x^i)\|$, sea menor que una tolerancia *tol* fijada de antemano. Si la convergencia no se satisface, volver al paso 2.1. Además, para evitar bucles infinitos se suele establecer un número máximo de iteraciones i_{max}, a partir del cual el bucle se rompe y el algoritmo finaliza.

La figura 3.1 muestra un diagrama de flujo que permite entender el algoritmo de una forma visual e intuitiva, así como facilitar su implementación numérica en caso de que fuese necesario, mientras que la figura 3.2 proporciona un esquema visual de cómo realmente funciona la técnica, en la que se combina observaciones y predicciones para corregir el estado atmosférico inicial.

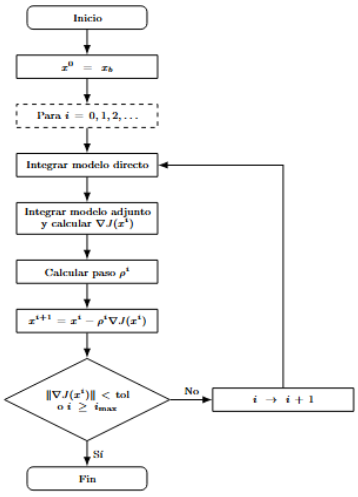


Figura 3.1: Implementación algorítmica del 4DVAR

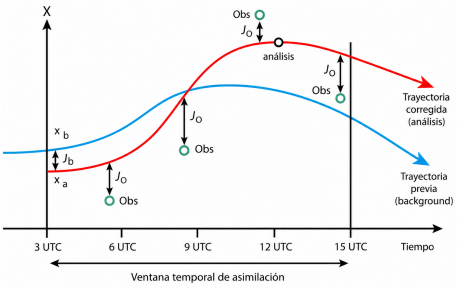


Figura 3.2: Esquema de funcionamiento del 4DVAR. Fuente: Adaptación de ECMWF ([8])

Sin embargo, aunque extremadamente útil, el algoritmo 4DVAR requiere en cada iteración la integración tanto del modelo dinámico completo como de su modelo adjunto, así como la minimización directa de una función de coste no lineal. En modelos operativos reales, donde el número de variables del sistema es del orden de $10^7 - 10^9$, esta minimización resulta algorítmicamente inviable. Para abordar estas limitaciones, en los últimos años organizaciones como ECMWF [10] han implementado una variante de esta técnica denominada *incremental 4DVAR* o 4DVAR incremental. En esta formulación se linealiza el modelo dinámico y el operador de observación alrededor de una trayectoria de referencia generada por el modelo no lineal. De este modo, el problema variacional original se aproxima por una sucesión de problemas cuadráticos que se resuelven iterativamente para el incremento del estado inicial. Bajo esta perspectiva, el

modelo lineal tangente describe la evolución temporal de pequeñas perturbaciones alrededor del estado de referencia, normalmente en términos de variables atmosféricas como temperatura, viento, humedad o presión en superficie. Este procedimiento reduce de forma significativa el coste computacional, manteniendo una aproximación iterativa al problema variacional original. No obstante, esta linealización constituye únicamente una aproximación, que puede resultar insuficiente si las observaciones se encuentran demasiado alejadas de la trayectoria de referencia considerada.

3.3. Filtros de Kalman vs Técnicas Variacionales: Discusión Comparativa

Como se ha explicado en las secciones anteriores, tanto las técnicas secuenciales como las variacionales resuelven el problema de reconstruir el estado atmosférico inicial a partir de un conjunto finito de observaciones. No obstante, ambas familias difieren de manera significativa en su forma de abordar el problema desde un punto de vista matemático. La tabla 3.1 resume estas diferencias estructurales, destacando los elementos conceptuales que distinguen ambos enfoques.

	Técnicas secuenciales (Filtros de Kalman)	**Técnicas variacionales** (3DVAR / 4DVAR)
Tiempo de actuación	Instante temporal t_i	Ventana $\{t_i\}_{i=0}^{k}$
Formalismo matemático	Propaga media y covarianza	Minimiza una función de coste $\mathcal{J}$
Área de aplicación natural	Actualización/predicción en tiempo real	Reanálisis meteorológicos
Coste computacional	Crece con la dimensión del estado	Depende de la linealidad del modelo y su adjunto
Problema que resuelven	Filtrado (*filtering*)	Suavizado (*smoothing*)

Cuadro 3.1: Comparativa entre técnicas secuenciales (Kalman y derivados) y técnicas variacionales (3D-Var/4D-Var).

Finalmente, aunque ambas familias parecen encontrarse en extremos radicalmente opuestos, en la práctica no existe una diferencia estricta entre enfoques secuenciales y variacionales. Actualmente existen esquemas híbridos, como los propuestos en [3] y [14] que combinan la formulación variacional con covarianzas estimadas mediante conjuntos, integrando la coherencia dinámica global que proporciona el 4DVAR con la representación adaptativa de los filtros de Kalman y sus derivados.

Capítulo 4

Implementación numérica de un sistema de DA. Metodología

En este capítulo se presenta la metodología para la implementación numérica del algoritmo de asimilación 4DVAR sobre el modelo de Lorenz-96 [12], con el objetivo de reconstruir el estado inicial del sistema a partir de una serie de observaciones dadas. Además, sobre este mismo modelo se llevan a cabo diferentes tests de sensibilidad del algoritmo, con el fin de evaluar de manera empírica sus fortalezas y limitaciones, así como la influencia en el rendimiento de parámetros clave como el ruido observacional o la longitud de la ventana de asimilación. Finalmente, se establece una comparación conceptual de esta implementación con los métodos empleados en reanálisis atmosféricos modernos.

4.1. El modelo Lorenz-96

El modelo Lorenz-96, introducido por Edward Lorenz en el año homónimo [16], es un sistema de ecuaciones diferenciales acopladas que describen la evolución de una magnitud escalar sujeta a diferentes fenómenos atmosféricos en un mallado circular. Propuesto inicialmente como un modelo de test para técnicas de predicción numérica, hoy en día sirve de soporte a la hora de desarrollar nuevas técnicas de asimilación de datos, debido a su estructura no lineal y su bajo coste computacional. En su propuesta, Lorenz diseña el modelo con el objetivo específico de replicar la advección atmosférica, la disipación de la energía y los posibles forzamientos externos. El resultado de estas consideraciones es un sistema gobernado por el sistema de ecuaciones diferenciales discretizadas

$$\frac{d}{dt}x_i(t) = x_{i-1}(t)\big(x_{i+1}(t) - x_{i-2}(t)\big) - x_i(t) + F \tag{4.1}$$

donde el término no lineal $x_{i-1}(t)\big(x_{i+1}(t) - x_{i-2}(t)\big)$ representa la advección, $-x_i(t)$ la disipación energética y F el forzamiento externo. En su propuesta inicial, además, el vector x es un vector de dimensión d =40, y para modelar realmente las características circulares del mallado de tamaño N se considera $x_{-1} = x_{N-1}, x_0 = x_N$ y $x_{N+1} = x_1$. Además, recientes trabajos como el de Kerin y Engler [12] prueban que para $F = 8$ el sistema entra en régimen caótico, como se puede observar en las figuras 4.1 y 4.2, lo que dota al sistema de ricas propiedades matemáticas.

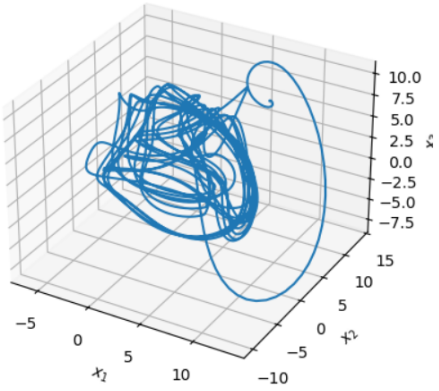


Figura 4.1: Trayectoria de 3 variables bajo el modelo Lorenz-96 con forzamiento $F = 8$.

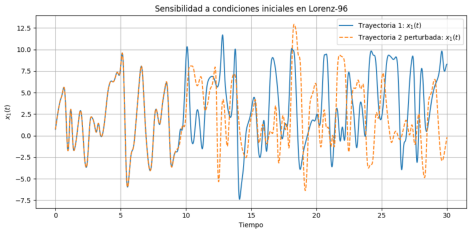


Figura 4.2: Trayectoria de $x_1(t), x_1(t) + \varepsilon$. Se observa que pequeñas perturbaciones en el estado inicial crecen exponencialmente en el tiempo, condición necesaria en un sistema caótico.

Así, siguiendo la literatura científica se toma el modelo Lorenz-96 con un término de forzamiento $F = 8$ como referencia sobre el que implementar la técnica 4DVAR. Esto se produce porque en el régimen caótico el sistema presenta una fuerte sensibilidad a las condiciones iniciales, por lo que pequeñas perturbaciones en el estado inicial crecen exponencialmente en el tiempo. Esta propiedad, ilustrada en la figura 4.2, es especialmente relevante en el contexto de la asimilación de datos, pues justifica la necesidad de estimar con precisión el estado inicial del sistema. En consecuencia, el Lorenz-96 en régimen caótico permite analizar, con un bajo coste computacional, la eficiencia de los algoritmos que reconstruyen el estado inicial a partir de observaciones parciales y ruidosas.

4.2. Configuración y diseño del experimento

En esta sección se describe la configuración del experimento numérico empleado para evaluar el rendimiento y eficiencia del algoritmo 4DVAR. Como se ha mencionado antes, el experimento se basa en un modelo de tipo Lorenz-96 y sigue el esquema clásico de experimento gemelo, en el que las observaciones se generan a partir de una simulación del propio modelo.

La configuración del experimento es la siguiente:

1. **Modelo dinámico:** Se considera el modelo de Lorenz-96 con dimensión $d = 40$, forzamiento constante $F = 8$ y condiciones de contorno cíclicas. La integración temporal se realiza mediante un esquema de Runge-Kutta de orden 4 con paso $\Delta t = 0{,}01$.

2. **Generación de la verdad:** Se genera una trayectoria de referencia (verdad) integrando el modelo a partir de un estado inicial x_0^{true} dado.

3. **Observaciones:** Las observaciones se construyen a partir de la verdad mediante un operador de observación parcial que devuelve solo un número $r < d$ de variables observadas. Además, en cada observación y_k se añade ruido gaussiano de desviación típica σ_{obs}, de forma que $y_k = \mathcal{H}(x_k^{true}) + \varepsilon_k$, con $\varepsilon_k \sim N(0, B), B = \sigma_{obs}^2 I$.

4. **Background:** El estado inicial de background x_b se obtiene perturbando el estado verdadero con ruido gaussiano de desviación típica σ_b, de forma que $x_b = x_0^{true} + \eta$, con $\eta \sim N(0, B), B = \sigma_b^2 I$. Como se ha comentado en capítulos anteriores, este background o estado de fondo sirve de punto de partida en el algoritmo, y se obtiene generalmente de reanálisis previos.

5. **Ventana temporal de asimilación:** Se considera una ventana temporal de n_{steps} pasos, con observaciones cada 5 pasos.

6. **Minimización:** El problema variacional se resuelve mediante un algoritmo de optimización iterativo 4DVAR, partiendo del background como estimación inicial. A partir del nuevo estado original se integra el modelo y se obtiene una trayectoria corregida que llamaremos análisis.

Esta configuración permite evaluar de forma controlada la capacidad del algoritmo para reconstruir el estado inicial del sistema a partir de información parcial y ruidosa. Además, con el objetivo de evaluar la robustez del algoritmo 4DVAR, se plantea en primer lugar un experimento base que sirve como referencia y cuyos valores numéricos pueden consultarse en el cuadro 4.1. Sobre esta configuración inicial se llevarán a cabo posteriormente distintos tests de sensibilidad, en los que se modifican de forma controlada ciertos parámetros del sistema para analizar su influencia en los resultados. En particular, se estudia la eficiencia del algoritmo en función del número de observaciones disponibles, del ruido observacional y de la longitud de la ventana de asimilación. Para evaluar el rendimiento del algoritmo se emplea el error cuadrático medio (RMSE), tanto en el estado inicial como a lo largo de la trayectoria temporal. En particular, se consideran:

- RMSE del estado inicial.
- RMSE de la trayectoria temporal.

donde dado un estado estimado x y el estado verdadero x^{true}, el RMSE del estado inicial y de la trayectoria se definen respectivamente como

$$\begin{aligned} \text{RMSE}_{\text{estado}} &= \sqrt{\frac{1}{d}\|x - x^{true}\|^2}, \\ \text{RMSE}_{\text{traj}} &= \sqrt{\frac{1}{(N+1)d}\sum_{k=0}^{N}\|x_k - x_k^{true}\|^2}. \end{aligned} \tag{4.2}$$

con d la dimensión del sistema y N el número de pasos temporales considerados en la ventana de asimilación. El código que ejecuta la simulación, basado enteramente en el diagrama de flujo de la figura 3.1, puede consultarse en GitHub-4DVAR; este hipervínculo conduce a un repositorio de GitHub que contiene el archivo. Es un código, escrito por el autor del trabajo e implementado en PYTHON, que se apoya de las librerías Numpy, Pyplot, SciPy y Jax. Mientras que las tres primeras son estándar en física computacional y sirven para cálculo numérico, graficado y optimización (respectivamente), la librería Jax es una alternativa numérica a Numpy que permite calcular gradientes automáticamente, lo que resulta de gran ayuda en el cálculo de $\nabla\mathcal{J}(x)$.

Parámetro del experimento	Valor numérico en experimento base
Dimensión d de los vectores de estado x	$d = 40$
Forzamiento F del modelo Lorenz-96	$F = 8$
Paso temporal de integración Δt	$\Delta t = 0,01$
Longitud n_{steps} de la ventana temporal de asimilación	$n_{steps} = 100$ pasos
Frecuencia con las que se toman las observaciones y_k	Observaciones cada 5 pasos
Desviación típica σ_{obs} del error en las observaciones	$\sigma_{obs} = 1$
Desviación típica σ_b del error del background	$\sigma_b = 1$

Cuadro 4.1: Valores numéricos en el experimento base de los diferentes parámetros de la simulación

Finalmente, resulta interesante comparar el experimento numérico que se va a llevar a cabo sobre el Lorenz-96, un modelo puramente académico, con los sistemas de reanálisis atmosférico utilizados en contextos operativos reales, como ERA5. Este es un reanálisis global desarrollado por el ECMWF [9], que combina un modelo atmosférico de alta resolución con una enorme cantidad de observaciones reales mediante técnicas basadas en asimilación de datos, fundamentalmente 4DVAR y sus derivadas [10].

En ERA5, la atmósfera se representa mediante una discretización espacial global, lo que da lugar a un sistema de gran dimensión que describe variables como temperatura potencial, vorticidad o presión a nivel de mar en cada punto de la malla [9]. Sobre esta discretización se integra un modelo numérico, mientras que las observaciones, que no coinciden en general con los puntos de la malla, se incorporan mediante operadores de observación adecuados. Así, la estimación del estado del sistema se realiza mediante técnicas variacionales de tipo 4DVAR, empleando una ventana temporal de asimilación de 12 horas [5]. El resultado final del reanálisis es un campo atmosférico coherente definido en toda la malla. Gracias a este reanálisis atmosférico se ha conseguido reconstruir la evolución de la atmósfera desde el año 1940 hasta el presente de una forma precisa, lo que ha sido de gran ayuda para comprender la evolución atmosférica y validar de forma empírica fenómenos como el cambio climático. La Figura 4.3 muestra un campo global de temperatura obtenido mediante el reanálisis ERA5.

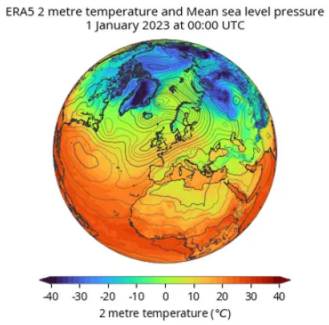


Figura 4.3: Campo global de temperatura a 2 metros obtenido mediante el reanálisis ERA5. Este tipo de productos corresponde a una estimación del estado de la atmósfera obtenida mediante la combinación de un modelo numérico y observaciones a través de técnicas de asimilación de datos. Fuente: ECMWF [5]

A pesar de la enorme diferencia de escala, este procedimiento es conceptualmente equivalente al desarrollado en este trabajo, donde el modelo de Lorenz-96 y el algoritmo 4DVAR se emplean para reconstruir el estado del sistema a partir de observaciones sintéticas. Así, aunque existen diferencias significativas, el experimento desarrollado en este capítulo reproduce a pequeña escala los elementos fundamentales de estos sistemas:

- El modelo de Lorenz-96 actúa como análogo simplificado de los modelos atmosféricos globales.
- El experimento gemelo reemplaza las observaciones reales por observaciones sintéticas generadas a partir del propio modelo.
- El estado de background y su incertidumbre representan la información previa disponible en los sistemas operativos.
- El algoritmo 4DVAR se emplea en ambos casos para estimar el estado inicial óptimo del sistema.

Capítulo 5

Resultados experimentales

En este capítulo se discuten los resultados obtenidos en la implementación numérica del capítulo anterior. En particular, se presenta un resultado que verifica la correcta implementación matemática del método, y tras exponer los resultados del experimento base, se muestran los resultados de los diferentes tests de sensibilidad, que muestran la influencia de los diferentes parámetros del sistema en el correcto rendimiento del algoritmo.

5.1. Validación del gradiente

Antes de analizar los resultados del algoritmo 4DVAR se ha llevado a cabo un test de validación del gradiente con el objetivo de verificar la correcta implementación del modelo adjunto, ya que la utilidad de esta técnica descansa en esencia sobre la precisión en su cálculo. Para ello, se compara el gradiente de la función de coste obtenido mediante el modelo adjunto con una aproximación por diferencias finitas. En particular, se analiza el comportamiento del cociente

$$\Phi(\alpha) = \frac{J(x + \alpha d) - J(x)}{\alpha \nabla J(x) \cdot d},$$

que debería tender a 1 cuando $\alpha \to 0$ si el gradiente está correctamente implementado. En efecto, la figura 5.1 muestra que tras un pico máximo en $\alpha = 10^{-6}$ el cociente Φ rápidamente tiende a 1 a medida que $\alpha \to 0$, lo que implica que el adjunto está bien implementado.

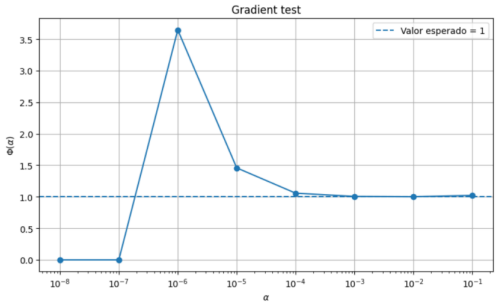


Figura 5.1: Test del gradiente para el modelo adjunto de $\mathcal{J}$. Al tender el cociente a 1 cuando $\alpha \to 0$, podemos concluir que el modelo adjunto está correctamente implementado

5.2. Resultados del experimento base

En primer lugar, se analiza la capacidad del algoritmo para reconstruir el estado inicial del sistema. En la figura 5.2 se comparan el estado verdadero, el background y el análisis obtenido tras la minimización. Se observa que el análisis se aproxima significativamente al estado verdadero, mejorando notablemente la estimación inicial proporcionada por el background.

A continuación, se estudia la evolución temporal de una de las variables observadas. En la figura 5.3 se representan la trayectoria verdadera, la trayectoria del background y la trayectoria del análisis, junto con las observaciones disponibles. Se aprecia que la trayectoria del análisis sigue de forma más fiel la evolución del sistema que la del background, incorporando adecuadamente la

información observacional.

La evolución del error se muestra en la figura 5.4, donde se representa el RMSE en función del tiempo tanto para el background como para el análisis. Se observa una reducción significativa del error en el caso del análisis, lo que indica la eficacia del algoritmo en la corrección del estado del sistema.

Finalmente, los cálculos del error cuadrático medio tanto del estado inicial como de la trayectoria en su conjunto, ilustrados en el cuadro 5.5, muestran que el algoritmo 4DVAR es capaz de reducir de forma significativa tanto el error en el estado inicial como en la trayectoria temporal del sistema.

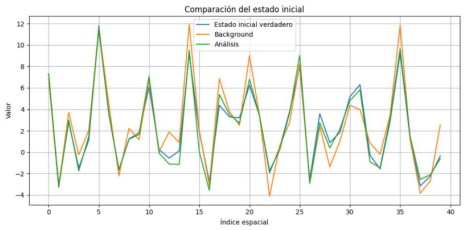


Figura 5.2: Reconstrucción de la trayectoria del sistema al aplicar la técnica 4DVAR.

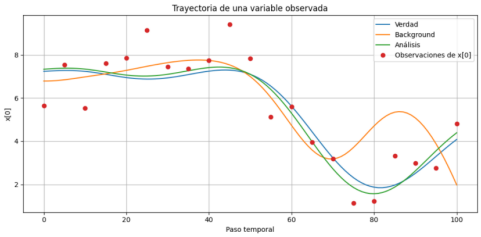


Figura 5.3: Evolución temporal de una de las variables observadas antes y después de aplicar el algoritmo, junto con las variables observadas.

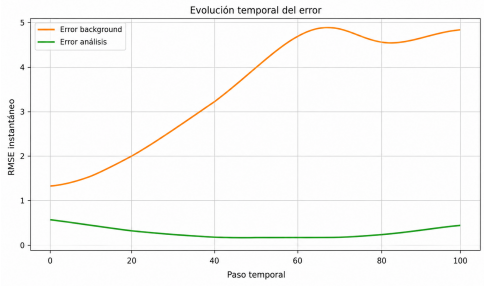


Figura 5.4: Evolución del error cuadrático medio tanto para el background como para la trayectoria corregida.

	Background	Análisis	Reducción (%)
$RMSE_{\text{estado}}$	1,38	0,58	57,36
$RMSE_{\text{traj}}$	3,77	0,34	90,84

Figura 5.5: Reducción del error cuadrático medio tanto para el estado inicial como para la trayectoria al aplicar el algoritmo 4DVAR.

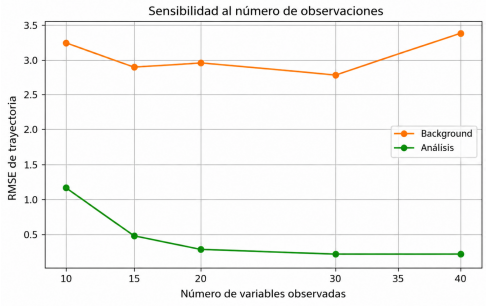
5.3. Análisis de sensibilidad

Como se ha comentado anteriormente, los tests de sensibilidad permiten evaluar la respuesta del algoritmo a la modificación de parámetros clave del experimento, así como evaluar la influencia de estos parámetros en los resultados numéricos. En primer lugar, se analiza el efecto del número de variables observadas en el rendimiento de la técnica. Como se puede ver en la figura 5.6a, al aumentar el número de variables observadas el error cuadrático medio de la trayectoria corregida se reduce significativamente, lo que muestra la importancia de las observaciones en el correcto funcionamiento del algoritmo.

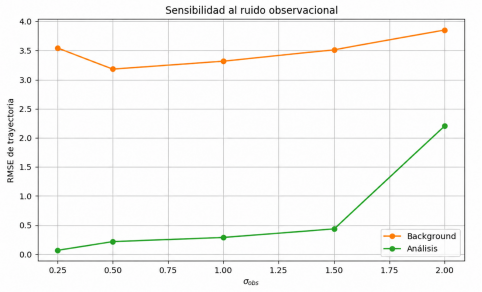
Por otro lado, la figura 5.6b muestra que un aumento del ruido observacional σ_{obs} aumenta de manera notable el RMSE de la trayectoria. Este es un resultado esperable, pues según la ecuación 3.2 al aumentar la matriz de covarianzas, las observaciones pierden influencia en la minimización,

y por tanto el análisis se vuelve más dependiente del modelo y del background. Como este background no es perfecto, este error se propaga en el tiempo motivado por el comportamiento caótico del modelo, lo que aumenta de manera sustancial el error cuadrático medio.

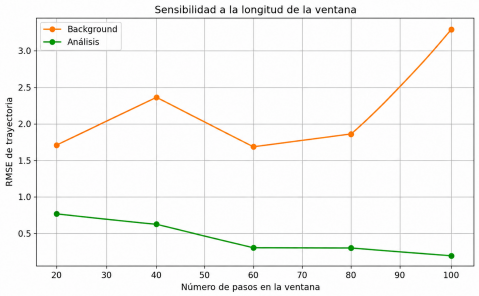
Finalmente, como se observa en la figura 5.6c, el incremento de la longitud de la ventana temporal de asimilación conduce a una reducción del error cuadrático medio de la trayectoria corregida. Este comportamiento, una vez más, es esperable pues una ventana más larga logra incorporar un mayor número de observaciones distribuidas en el tiempo, lo que incrementa la información disponible. No obstante, este efecto es válido mientras el modelo proporcione una representación adecuada de la dinámica en el intervalo considerado, y ventanas extremadamente largas pueden degradar la calidad del análisis al ser el Lorenz-96 un sistema caótico en el que estados inicialmente muy juntos divergen rápidamente en el tiempo. Esta es la razón por la que en modelos operativos actuales de reanálisis, la longitud de la ventana temporal de asimilación se sitúa típicamente en un intervalo de entre 6 y 12 horas.



(a) RMSE de la trayectoria al variar el número de variables observadas.



(b) RMSE de la trayectoria al variar el ruido observacional.



(c) RMSE de la trayectoria al variar la longitud de la ventana temporal de asimilación.

Figura 5.6: Tests de sensibilidad del 4DVAR sobre: número de variables observadas, ruido observacional y longitud de la ventana temporal de asimilación.

En conjunto, los resultados obtenidos muestran que la eficiencia del algoritmo 4DVAR depende de forma significativa de la cantidad y calidad de la información observacional disponible, así como de la longitud de la ventana temporal de asimilación. Estos resultados ponen de manifiesto tanto el potencial como las limitaciones del método en contextos prácticos.

Capítulo 6

Conclusiones y perspectivas futuras

En este trabajo se ha hecho una revisión bibliográfica de las principales técnicas de asimilación de datos en resultados de modelos meteorológicos, e implementado numéricamente una de estas técnicas, evaluando su robustez y eficiencia. Tras introducir el marco matemático general en el que se basan las técnica, así como la clasificación usada por expertos en el área para distinguirlas según si actualizan la información paso a paso u optimizan de manera global en una ventana temporal de asimilación, se ha profundizado a fondo en cada una de las familias, presentando además un ejemplo paradigmático de cada una. En particular, por la importancia en los reanálisis meteorológicos y la extensión en su uso se ha hecho especial hincapié en las técnicas variacionales, presentando de manera algorítmica la técnica 4DVAR por ser la herramienta más usada en este campo.

Posteriormente, se ha implementado esta técnica 4DVAR en un ordenador personal, con el objetivo de mostrar de manera explícita y numérica su funcionamiento y eficiencia. Así, en primer lugar se ha presentado el modelo académico Lorenz-96 como referencia sobre el que trabajar, y tras exponer su comportamiento caótico bajo cierta asignación de parámetros se ha demostrado que efectivamente el modelo exhibe dependencia sensible de las condiciones iniciales, lo que valida su utilidad como escenario en el que aplicar las técnicas de asimilación. Así, se ha programado en PYTHON un código propio, disponible en GitHub-4DVAR, que implementa sobre el Lorenz-96 la técnica 4DVAR. Tras un experimento base en el que se ha mostrado que la técnica cumple con exactitud la función de reconstruir de manera óptima el estado inicial, combinando para ello simulaciones previas y observaciones disponibles, se han llevado a cabo diferentes experimentos de sensibilidad, en los que se ha observado cómo el número de variables observadas o la longitud de la ventana temporal de asimilación mejoran significativamente el análisis, mientras que el ruido observacional lo empeora. En consecuencia, se concluye que las técnicas de asimilación de datos y de reanálisis no deben entenderse únicamente como una herramienta matemática de corrección, sino como el marco fundamental mediante el cual reconstruimos, de manera coherente y dinámica, la realidad de sistemas caóticos a partir de información incompleta, y sobre el que descansa, en última instancia, la propia posibilidad de predecir el futuro climático.

No obstante, aunque el desarrollo tecnológico y computacional de finales del siglo pasado y principios del actual ha facilitado enormemente la implementación de estas técnicas de asimilación, actualmente estos métodos enfrentan una serie de desafíos teórico-prácticos que siguen motivando su investigación y desarrollo, principalmente relacionados con la no linealidad de los modelos, la modelización del error o el coste computacional asociado. En los próximos años se espera que la asimilación de datos consiga adaptarse a la creciente dimensión de los sistemas operativos, del orden de 10^8 variables, así como integrar correctamente la masiva cantidad de datos heterogéneos procedentes de fuentes cada vez más diversificadas. Además, se espera también que el desarrollo de herramientas y plataformas de inteligencia artificial y aprendizaje automático se acople a la asimilación de datos, ya sea como complemento a la modelización de los errores del modelo y las observaciones o como ayuda para construir aproximaciones eficientes de los operadores dinámicos y de observación. En este sentido, modelos como como el propuesto por Dong et al.[7] se sirven de redes neuronales, entrenadas con observaciones reales, que reemplazan el modelo dinámico, mejorando significativamente la eficiencia de la asimilación y reduciendo el tiempo de coste. En consecuencia, podemos decir que la asimilación de datos constituye, a día de hoy, un campo de investigación abierto, en el que se espera se hagan grandes progresos en el futuro.

Bibliografía

[1] Peter R. Ahnert, Witold F. Krajewski, and Edward R. Johnson. Kalman filter estimation of radar–rainfall field bias. In *23rd Conference on Radar Meteorology*, Snowmass, Colorado, 1986. American Meteorological Society.

[2] Esteban Alonso-González, Kristoffer Aalstad, Mohamed Wassim Baba, Jesús Revuelto, Juan Ignacio López-Moreno, Joel Fiddes, Richard Essery, and Simon Gascoin. The multiple snow data assimilation system (musa v1.0). *Geoscientific Model Development*, 15:9127–9155, 2022.

[3] Dale M. Barker and Alan M. Clayton. Hybrid variational-ensemble data assimilation. In *ECMWF Seminar on Data Assimilation for Atmosphere and Ocean*, pages 31–44, Reading, UK, 2011.

[4] Françoise Bouttier. The kalman filter. *ECMWF Seminar on Data Assimilation*, 1994.

[5] Copernicus Climate Change Service (C3S). Era5 monthly averaged data on single levels from 1940 to present, 2019. Accessed: 2026-03-19.

[6] Robert L. Devaney. *An Introduction to Chaotic Dynamical Systems*. Addison-Wesley, Redwood City, CA, 2 edition, 1989.

[7] Renze Dong, Hongze Leng, Chengwu Zhao, Junqiang Song, Juan Zhao, and Xiaoqun Cao. A hybrid data assimilation system based on machine learning. *Frontiers in Earth Science*, 10:1012165, 2023.

[8] ECMWF. 20 years of 4d-var: Better forecasts through a better use of observations. `https://www.ecmwf.int/en/about/media-centre/news/2017/20-years-4d-var-better-forecasts-through-better-use-observations`, 2017. Accessed: 2026.

[9] European Centre for Medium-Range Weather Forecasts (ECMWF). Ecmwf reanalysis v5 (era5). `https://www.ecmwf.int/en/forecasts/dataset/ecmwf-reanalysis-v5`, 2026. Accessed: 2026-03-19.

[10] M. Janisková and P. Lopez. Linearised physics: the heart of ecmwf's 4d-var. *ECMWF Newsletter*, (175):20–26, 2023.

[11] Eugenia Kalnay. *Atmospheric Modeling, Data Assimilation and Predictability*. Cambridge University Press, Cambridge, 2003.

[12] John Kerin and Hans Engler. On the lorenz '96 model and some generalizations. 2020.

[13] Kody J. H. Law, Andrew M. Stuart, and Konstantinos C. Zygalakis. *Data Assimilation: A Mathematical Introduction*, volume 62 of *Texts in Applied Mathematics*. Springer, 2015.

[14] Andrew C. Lorenc. The potential of the ensemble kalman filter for nwp—a comparison with 4d-var. *Quarterly Journal of the Royal Meteorological Society*, 129(595):3183–3203, 2003.

[15] Edward N. Lorenz. Deterministic nonperiodic flow. *Journal of the Atmospheric Sciences*, 20(2):130–141, 1963.

[16] Edward N. Lorenz. Predictability: A problem partly solved. *ECMWF Seminar on Predictability*, pages 1–18, 1996.

[17] Ionel M. Navon. Data assimilation for numerical weather prediction: A review. In Seon Ki Park and Liang Xu, editors, *Data Assimilation for Atmospheric, Oceanic and Hydrologic Applications*, pages 21–65. Springer, 2009.

[18] Florence Rabier and Zhiquan Liu. Variational data assimilation: Theory and overview. *Proceedings of the ECMWF Seminar on Recent Developments in Data Assimilation for Atmosphere and Ocean*, pages 29–43, 2006.

[19] Olivier Talagrand. Assimilation of observations, an introduction. *Journal of the Meteorological Society of Japan*, 75(1B):191–209, 1997.